

# 透過實際案例學習如何撰寫好的求職履歷 - 使用文字探勘技術之初步研究

李昀潔, 資管博一

呂孟芸, 國企四

張譯心, 國企四

陳韋霖, 資工碩一

詹雅安, 會計四

對於學生而言，除了努力完成學業或完成研究以取得畢業之外，如何透過簡歷 (Resume) 的撰寫去應徵企業的招募也是一件重要的事。然而如何撰寫簡歷不是一件簡單的。因此我們小組從網際網路上找到履歷的開放資料集，透過分群方法 (Clustering) 來對該資料集進行研究，我們檢驗履歷的寫法是否能對應到公司招聘的職位，另外我們也找出一些能夠申請多種工作類別的簡歷寫法，依本專案之結果發現，其資料集之內容應符合常識，意即該些申請對應之職缺與透過演算法的自動分群結果比較，並無顯著差異，另外似乎沒看到有趣之具跨領域特性之履歷，不過我們也找出並整理了一些寫法上可以加強品質之履歷，此次研究希望透過該開放資料集所作的初步研究，希望能對學生們製作個人簡歷上能有所幫助。

CCS Concepts: • **Applied computing** → **Document management and text processing**;

## ACM Reference Format:

李昀潔, 呂孟芸, 張譯心, 陳韋霖, and 詹雅安. 2022. 透過實際案例學習如何撰寫好的求職履歷 - 使用文字探勘技術之初步研究. 1, 1 (January 2022), 8 pages. <https://doi.org/10.1145/nnnnnnn.nnnnnnn>

## 1 研究目標

投履歷找工作時，如何撰寫一份符合業主要求的履歷，尤其對於高度專業的工作而言，更顯重要，然如何撰寫履歷等事宜，雖坊間有許多教條方法供大眾學習，但寫法上需考慮求職者的狀況，並無法直接使用法則來套用。有鑑於此，我們使用網路上公開之求職簡歷資料，運用課堂所學習之文字探勘技術來針對該些資料進行分析，藉此探求有趣的訊息以幫助求職者來面對如何撰寫履歷之問題，於本專案中，我們設定了兩個主題

Authors' addresses: 李昀潔, 資管博一; 呂孟芸, 國企四; 張譯心, 國企四; 陳韋霖, 資工碩一; 詹雅安, 會計四.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from [permissions@acm.org](mailto:permissions@acm.org).

© 2022 Association for Computing Machinery.

XXXX-XXXX/2022/1-ART \$15.00

<https://doi.org/10.1145/nnnnnnn.nnnnnnn>




Fig. 1. The counting for each application catogery in resume

進行探討，其一為驗測該些資料是否各對應之履歷內容是否符合該求職之工作，其二為找出部份具有跨領域寫法之履歷。

2 研究方法

本專案中，我們所探討之資料，為從網路上所抓下來之公開資料，而該些資料除了各履歷的內容外，也包含了各別履歷所對應之求職職位。

以文字探勘而言，雖然求職職位與其履歷資料這兩種資料型可視為一種監督式學習技術之應用（Supervised Learning）[7]。然於本專案中，欲探討之主體非以分類問題之面象而進行之，而是希望從資料本身特性出發，藉由資料分析方法，試圖找出有趣的履歷範本，意即透過非監督式學習技術（Unsupervised Learning）[7]。

關於分析內容，共分為兩項工作，第一我們先檢驗資料集內容是符合常識，意即我們想確認是否各求職類別是否對應該些求職履歷，透過分群的方法去檢驗是否各群集（Cluster）內是否有內聚，第二透過分析資料內容，找出部份具有跨領域之履歷資料並作為範本供讀者參考，其方法上我們視此該些資料視為資料探勘問題 [4]，以找出適合之履歷資料。

2.1 資料集

針對履歷資料，我使用了公開資料集作為本專案之資料，其以 Kaggle 網站公開之實際之工作求職者履歷資料進行分析 [1]，該資料共擁有三個欄位，分別為 ID，Resume\_str，Resume\_html 及 Category，ID 欄位表示流水號，中間兩欄位分別為 Resume 的純文字及其原始抓下來的格式（內含 HTML 標籤），Category 表示對應所求職之職位名，此資料集共有 24 個求職職位，求職種類及數量表可參照圖. 1。資料集共有 2484 筆資料，意即共有 2484 筆 resume。

## 2.2 資料前處理

於本專案中，我們主要進行兩項工作，然而在進行之前，我們需要進行資料前處理工作，才能將履歷資料轉換成我們可以分析的資料，在開始分析前，我們會將履歷中各個多餘空格去除，避免該些空格造成分析上的偏誤。

我們透過使用 Sentence-Transformers[9] 工具，將資料集之真實履歷資料，透過 BERT 方法 [3]，將該些履歷內的文字，轉成合適之 word embeddings。該些 word embeddings 為資料集中，所有履歷之文字，經過轉換後之新資料表示法，其原因為，若不經過轉換，原始資料中所有文字所表示之方法，其通常表示法可能為詞袋（bag of word）或是 one-hot encoding 編碼等，但這些表示法都有空間浪費的問題，因為所有文字所產生之矩陣（Matrix）都具有高度稀疏性 [10]，因此透過 BERT 轉換 [3]，將原有的矩陣維度進行降維（dimension reduction），可在保存原有資料的特徵外，減少了原本高度稀疏所造成的問題。

## 2.3 履歷一致性

在取得 word embeddings 後，我們會先針對此資料，使用 python 的 sklearn[2] 套件，使用資料探勘之常見分群方法（k-means clustering）進行檢驗 [4]，其目的為確保該些履歷資料具有可信性，意即針對特定群體之履歷，其所對應之相同職缺，該些個別履歷資料之特性應具有相似性，我們將採用 k-means 分群方法 [6] 進行分析。

## 2.4 跨領域範本

我們希望能找到是否有具跨領域性質之履歷，因此希望找出該些履歷離所屬之職務類別之核心履歷越遠越好，且該履歷可能與其他職缺很相近。

因此為達此目的，我們共進行三個步驟，首先，我們計算各職缺類別之平均中心向量如公式 1 所示，之後我們將利用平均中心向量求得各職務群內之核心履歷  $\hat{d}$  如公式 2 所示，再將該核心履歷  $\hat{d}$  拿來求得該職務群內最不相似之履歷  $d^*$ ，如公式 3 所示，並將其視為具有跨領域性質之履歷，其計算相似度之方法，我們使用餘弦相似度計算式（cosine similarity）[10]，最後我們用  $d^*$  來計算離其最近之職務群如公式 4 所示，用以來觀察該履歷  $d^*$  是否具有跨領域之性質。

$$\bar{d}_c := \frac{1}{|d_c|} \sum_{i=1}^{|d_c|} d_{c,i}, \quad c \in C, d \in D. \quad (1)$$

$$\hat{d}_c := \arg \max_{c \in C, d \in D} \text{sim}(\bar{d}, d_{k \in c}). \quad (2)$$

$$d_c^* := \arg \min_{c \in C, d \in D} \text{sim}(\hat{d}_c, d_{k \in c}). \quad (3)$$




Fig. 2. Elbow method for optimal clustering number




Fig. 3. The result of t-SNE for k-means clustering

$$D_{c'} := \{c' \in C, c \in C, c' \neq c, d \in D : \arg \min sim(d_c^*, \bar{d}_{c'})\} \quad (4)$$

### 3 研究結果

於本專案中，我們所使用之實驗機器規格為一般配有 GPU 之個人電腦，CPU 為 AMD Ryzen Threadripper 1920X 12-Core Processor，其核心數為 24，作業系統版本為 Ubuntu 16.04.5 LTS，記憶體為 125G，GPU 為 GeForce RTX 2080 Ti。

#### 3.1 履歷一致性

為了要檢驗資料中的履歷是否與該申請之職缺相符，我們使用了 k-means[6] 作為分群方法，利用 elbow method 來取得最適分群數 (Optimal clustering number)，其結果如圖. 2，




Fig. 4. The result of PCA for k-means clustering

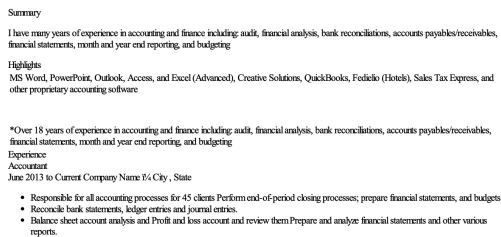


Fig. 5. The resume  $\hat{d}$  of category ‘ACCOUNTTANT’

所得值為 18，對照原來之職缺總數共計 24 項，可看出差距雖為 6，應不是顯著數字，從此差距數字下，我們可推論不同的申請之職業類別的群集結與自動分群結果相似，

另外我們也使用了 Adjusted Rand Index 來評價分群的結果 [5]，k-means 分群結果所得之 Adjusted Rand Index 為 0.192，其值大於零，因此具有分群結果具有可信性，然其值看似不接近於 1，可推論為該些履歷內含有求職者個人化訊息，加大了資料間的離散程度。

針對結果，我們採用 PCA (Princial Component Analysis) [8] [4] 將 k-means 之分群結果進行降維，將 word embeddings 維數降成兩維，如圖. 4所示，各顏色代表各別之職缺類別，由此圖可看出類別間應具一定的差異性。

另一方面，雖 PCA 為資料探勘之常見方法，但因為資料全為文字，所以我也使用了 t-SNE (t-Distributed Stochastic Neighbor Embedding) [11] 作為補助判斷，如圖. 3所示，各顏色代表各別之職缺類別，雖不若 PCA 結果如此一致，但仍可看出各類別間的分群結果具有一定差異性。

$c$	$c'$	$\hat{d}$	$d^*$	similarity
ACCOUNTANT	FITNESS	21338490	24799301	0.62522
ADVOCATE	HEALTHCARE	36392131	21614256	0.45807
AGRICULTURE	DIGITAL-MEDIA	19532392	34141299	0.53679
APPAREL	ADVOCATE	27176039	35121930	0.58595
ARTS	ENGINEERING	36379931	26069113	0.33301
AUTOMOBILE	BPO	15210069	18448085	0.59860
AVIATION	ARTS	16279537	12239749	0.66597
BANKING	FITNESS	21645690	18369400	0.29481
BPO	ENGINEERING	16492045	63158213	0.53825
BUSINESS-DEVELOPMENT	INFORMATION-TECHNOLOGY	98379112	12632728	0.10875
CHEF	ARTS	20321582	47317494	0.59843
CONSTRUCTION	DESIGNER	29894080	22983516	0.65415
CONSULTANT	AGRICULTURE	32433431	21512769	0.58459
DESIGNER	PUBLIC-RELATIONS	38565119	39434376	0.46325
DIGITAL-MEDIA	INFORMATION-TECHNOLOGY	14945250	11005406	0.58227
ENGINEERING	BPO	25608963	12022566	0.43318
FINANCE	PUBLIC-RELATIONS	11441764	20836112	0.65782
FITNESS	ENGINEERING	29165698	22488036	0.63132
HEALTHCARE	PUBLIC-RELATIONS	13565152	10480456	0.49030
HR	HEALTHCARE	34740556	39081840	0.60773
INFORMATION-TECHNOLOGY	AGRICULTURE	15791766	17987433	0.38101
PUBLIC-RELATIONS	CHEF	28290448	26127853	0.69702
SALES	BPO	19582792	12351749	0.60625
TEACHER	AGRICULTURE	19918523	24791126	0.58996

表 1. The detail of result of finding  $d^*$ .

3.2 跨領域範本

表. 1呈現本專案中所出之各類別中具有跨領域性質之履歷表，右邊欄位 ‘similarity’ 意思為  $d^*$  與  $\bar{d}_{c'}$  之相似度，比對各個相關性（Cosine Similarity），該些數值皆可看出不高，推測應為該些履歷表除了有跨領域性質外，另一層面，可能也代表了該些履歷表的品質不若其他同類型之履歷表高，舉例而言，圖. 5及圖. 6分別代表 ACCOUNTANT 類別的兩種履歷（ $\hat{d}$ ,  $d^*$ ），可看出兩者的差別在於，後者的履歷相較於前者的履歷而言，對於 ACCOUNTTANT 的文字較少著墨，因此也可推斷為該履歷相較之下較不易辨別為申請 ACCOUNTANT 工作。

ACCOUNTANT  
Summary  
Accountant for a Medium sized Company  
Experience  
01/2009 to Current  
Accountant Company Name 1/4 City, State

- Hired by their CPA firm to handle all accounting and job cost Reporting.

01/2007 to 01/2009  
Accountant Company Name 1/4 City, State

- Hired by their CPA firm to handle all accounting functions..

01/1997 to 01/2007  
Accountant Company Name 1/4 City, State

- Installed new Peachtree Accounting System
- Installed new computer system using a local area network and Added a Web site.

Fig. 6. The resume  $d^b$  of category ‘ACCOUNTTANT’

至於跨領域性質之履歷資料，依表. 1之 *similarity* 結果而言，似看不出顯著高之結果，可能因為不同職缺要求之文字上的差異較大，因此依此結果，可能找不到適合有跨領域特性之履歷。

4 結論

於本專案，我們針對了網路公開之真實履歷資料進行了初步之文字探勘，針對了該些履歷資料，我們共進行了兩個步驟，其一為檢驗該些履歷是否符合我們一般常識，其二找出是否具有跨領域性質之履歷。

關於檢驗履歷，我們使用了 *k-means* 作為分群方法，在分析的過程中，我們可看出該些履歷的分群結果數量，與其原本求職職缺的類別數未相異過大，再輔以資料視覺化之方法，推斷本專案所使用之資料來符合我們常識且分析結果具有可信性。

再者我們將該些履歷資料進一步分析，以期找出合適之具跨領域之履歷資料，然該依結果而言，似乎看不出有趣之履歷資料，但也看到一些履歷在撰寫上，不同品質上之差異，易言之，在履歷撰寫上，提及跟職缺相關之文字於履歷中，或許對履歷之品質提昇或有幫助，因此我們也整理後附上了那些可參照之履歷（相關性高及相關性低），以供讀者參照去查看原始履歷。

ACKNOWLEDGMENTS

謝謝老師上課所教授之知識，使得我們能得以完成此次報告研究。

REFERENCES

[1] Snehaan Bhawal. 2021. Resume Dataset. <https://www.kaggle.com/snehaanbhawal/resume-dataset>. Accessed: 2021-12-30.

[2] Lars Buitinck, Gilles Louppe, Mathieu Blondel, Fabian Pedregosa, Andreas Mueller, Olivier Grisel, Vlad Niculae, Peter Prettenhofer, Alexandre Gramfort, Jaques Grobler, Robert Layton, Jake VanderPlas, Arnaud Joly, Brian Holt, and Gaël Varoquaux. 2013. API design for machine learning software: experiences from the scikit-learn project. In *ECML PKDD Workshop: Languages for Data Mining and Machine Learning*. 108–122.

- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805* (2018).
- [4] Jiawei Han, Jian Pei, and Micheline Kamber. 2011. *Data mining: concepts and techniques*. Elsevier.
- [5] Lawrence Hubert and Phipps Arabie. 1985. Comparing partitions. *Journal of classification* 2, 1 (1985), 193–218.
- [6] James MacQueen et al. 1967. Some methods for classification and analysis of multivariate observations. In *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*, Vol. 1. Oakland, CA, USA, 281–297.
- [7] Kevin P Murphy. 2012. *Machine learning: a probabilistic perspective*. MIT press.
- [8] Karl Pearson. 1901. LIII. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin philosophical magazine and journal of science* 2, 11 (1901), 559–572.
- [9] Nils Reimers and Iryna Gurevych. 2020. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. *arXiv preprint arXiv:2004.09813* (04 2020). <http://arxiv.org/abs/2004.09813>
- [10] Hinrich Schütze, Christopher D Manning, and Prabhakar Raghavan. 2008. *Introduction to information retrieval*. Vol. 39. Cambridge University Press Cambridge.
- [11] Laurens Van der Maaten and Geoffrey Hinton. 2008. Visualizing data using t-SNE. *Journal of machine learning research* 9, 11 (2008).